

α,β-CROWN 을 활용한 외부 PyTorch 모델 강건성 검증

Reliable and Trustworthy Artificial Intelligence · Assignment #4

초록. 본 보고서는 α,β-CROWN 의 모델 및 설정 구조를 조사하고, 기본 예제에 포함되지 않은 외부 PyTorch 모델을 대상으로 로컬 강건성 검증을 수행한 결과를 정리한다. 과제 3 의 Marabou 가 SMT 기반 제약 해결 방식에 가까웠다면, α,β-CROWN 은 bound propagation 과 branch-and-bound 를 결합해 출력 경계를 계산한다. 본 과제에서는 작은 외부 PyTorch 모델을 직접 만들고, YAML 설정과 자동 실행 스크립트를 구성한 뒤 실제 verifier 실행 결과까지 기록했다.

1. α,β-CROWN 모델 및 설정 구조 조사

α,β-CROWN 의 실행은 `abcrown.py --config <yaml>` 형태로 이루어진다. 모델, 데이터셋, 검증 속성, solver 옵션이 하나의 YAML 파일에 정리되므로 실험 조건을 재현하기 쉽다. `complete_verifier/models` 에는 toy 모델, CIFAR 계열 CNN/ResNet, VNN-COMP 용 모델, non-ReLU 모델, custom specification 예제가 포함되어 있고, `complete_verifier/exp_configs` 에는 tutorial 예제와 벤치마크별 YAML 설정이 분리되어 있다.

Marabou 에서는 입력 bounds 와 출력 제약을 코드에서 직접 구성하는 경우가 많았지만, α,β-CROWN 에서는 모델 경로, 데이터 로더, norm, epsilon, timeout, branching strategy 등을 YAML 에 명시한다. 이 방식은 반복 실험에는 유리하지만, 처음 사용할 때는 α,β-CROWN 이 기대하는 key 이름과 커스텀 loader 형식을 정확히 맞춰야 한다.

2. 외부 모델과 데이터셋 구성

외부 모델은 2 차원 Gaussian cloud 를 분류하는 작은 PyTorch MLP 이다. 데이터는 `[0, 1]` 범위로 정규화했고, 모델은 `Linear(2, 16) -> ReLU -> Linear(16, 2)` 구조이다. 입력 차원이 낮고 네트워크가 작아 검증기 설정을 확인하기에 적합하다.

항목	내용
모델 파일	<code>models/toy_binary_mlp.pt</code>
모델 구조	2 입력, hidden 16, ReLU, 2 출력 MLP
데이터셋	<code>data/toy_dataset.csv</code>
커스텀 로더	<code>custom/toy_model_data.py</code>
검증 설정	<code>configs/toy_linf_robustness.yaml</code>
검증 속성	기준 입력 주변 L_{∞} 반경 <code>epsilon=0.05</code> 로컬 강건성

검증 property 는 기준 샘플 주변의 작은 perturbation 영역 안에서 모델의 분류 결과가 유지되는지 확인하는 문제로 설정했다. 커스텀 dataloader 는 α,β-CROWN 형식에 맞게 (`x`, `labels`, `data_max`, `data_min`, `eps`)를 반환하도록 작성했다.

3. 실행 파이프라인 및 결과

`run_all.sh` 는 conda 환경을 준비하고, 모델과 데이터 파일이 없으면 생성한 뒤, alpha-beta-CROWN 저장소가 없으면 `external/alpha-beta-CROWN` 에 clone 한다. 이후 공식 `complete_verifier/environment.yaml` 로 `alpha-beta-crown` 환경을 만들고, 그 환경의 Python 으로 `abcrown.py` 를 실행한다.

항목	결과
전체 스크립트	<code>./run_all.sh --timeout 60</code> 정상 종료
test.py 상태	verified
return code	0
test.py 측정 시간	약 4.71 초
α,β-CROWN 검증 시간	약 0.048 초
요약	1 개 instance 중 1 개 safe verified, falsified 0 개, timeout 0 개

초기 CROWN bound 만으로 검증이 끝났고, branch-and-bound 를 깊게 진행하기 전에 safe-incomplete 결과가 나왔다. 모델과 입력 차원이

매우 작고 기준점의 분류 margin 이 큰 편이어서, $\epsilon=0.05$ 범위에서는 출력 차이가 충분히 유지된 것으로 해석된다.

4. Marabou 와의 비교 및 해석

Marabou 는 입력 변수와 출력 제약을 명시적으로 구성하면서 검증 조건을 직접 다룰 수 있다는 장점이 있다. 반면 α,β -CROWN 은 YAML 설정을 중심으로 모델, 데이터, specification, solver 를 묶어 관리하므로 실험 조건을 재사용하기 쉽다. 특히 bound propagation 과 branch-and-bound 를 활용하기 때문에 큰 ReLU 네트워크에서는 Marabou 보다 확장성 있는 검증을 기대할 수 있다.

이번 실험에서 가장 크게 느낀 차이는 환경과 설정 파일의 중요성이다. 처음 작성한 설정에서는 최신 공식 config 에 없는 key 를 사용해 실패했지만, 공식 tutorial 형식에 맞춰 `specification.type: lp` 와 `data.dataset: Customized(...)` 형태로 바꾸자 정상적으로 실행되었다.

5. 한계 및 결론

본 실험은 작은 2 차원 MLP 에 대한 단일 로컬 강건성 검증이므로, 대형 이미지 모델에서의 성능을 직접 보여주지는 않는다. 그러나 외부 PyTorch 모델을 α,β -CROWN 형식에 맞게 연결하고, 자동 실행 스크립트로 설치부터 검증 결과 기록까지 재현 가능하게 만든 점에서 과제의 핵심 요구사항을 만족한다.

결론적으로 α,β -CROWN 은 설정 기반 실험 관리와 빠른 bound 기반 검증 측면에서 강점이 있다. 반면 초기 환경 구성과 YAML 형식 이해가 필수적이므로, 작은 외부 모델로 먼저 파이프라인을 검증한 뒤 더 큰 모델로 확장하는 접근이 적절하다고 판단했다.